O desempenho dos times do Clube dos 13 contra equipes que foram rebaixadas no Campeonato Brasileiro: uma análise baseada em dados

Luan Kauan Alves dos Santos[1], **Renato Miranda Filho**[1]

[1]Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais (IFMG)
Sabará - MG - Brasil

luankauan10@gmail.com, renato.miranda@ifmg.edu.br

Abstract. *This paper investigates, using a data-driven approach, whether the perception that large Brazilian clubs often drop points against the four teams in the relegation zone (Z4) holds true, and which contextual factors are associated with these results. We analyzed 4,898 match records (3,498 unique matches) of the Clube dos 13 teams in the Brazilian Série A between 2015 and 2025, collected from Sofascore and FBref. Decision trees were built for all clubs together, for the matches against the Z4, for the matches against the remaining opponents, for Atlético Mineiro (as a case study) and for each season. Against the Z4, the teams belonging to the Clube dos 13 won 55.7% of the matches, compared with 38.1% against the remaining opponents. Home advantage was the variable most associated with the result, appearing among the five most important variables in 10 of the 11 seasons. The trees help interpret the factors associated with match outcomes, without implying a cause-and-effect relationship.*

Resumo. *Este trabalho investiga, por meio de uma abordagem baseada em dados, se a percepção de que os grandes clubes brasileiros perdem pontos com frequência contra os quatro times da zona de rebaixamento (Z4) se confirma e quais fatores contextuais estão associados a esses resultados. Foram analisados 4.898 registros de partidas (3.498 partidas únicas) dos clubes do Clube dos 13 na Série A entre 2015 e 2025, coletados do Sofascore e do FBref. Foram construídas árvores de decisão para o conjunto dos clubes, para os jogos contra o Z4, para os jogos contra os demais adversários, para o Atlético Mineiro (estudo de caso) e para cada temporada. Contra o Z4, os times pertencentes ao Clube dos 13 venceram 55,7% das partidas, contra 38,1% diante dos demais adversários. A condição de mando foi a variável mais associada ao resultado, estando entre as cinco mais importantes em 10 das 11 temporadas. As árvores ajudam a interpretar os fatores associados ao resultado das partidas, sem que isso signifique uma relação de causa e efeito.*

1. Introdução

O futebol é frequentemente descrito na literatura como o esporte mais popular do mundo [Cayo 2013, Triches 2020]. Diante de sua enorme relevância cultural e econômica, as formas de captar e analisar estatísticas esportivas crescem de maneira acelerada. Novas ferramentas e portais surgem continuamente para entregar informações precisas a torce-

dores, comissões técnicas e organizações[1]. Nesse cenário, a análise de dados deixou de ser exclusividade dos grandes clubes e passou a integrar o debate público e acadêmico, abrindo espaço para investigações que unem desempenho em campo e inteligência de dados.

Nas arquibancadas, os torcedores desenvolvem percepções que nem sempre refletem a realidade dos fatos. Essas percepções podem ser moldadas por resultados recentes, por aspectos culturais ou por experiências acumuladas ao longo de anos de acompanhamento das partidas. Entre torcedores de futebol, é comum a percepção de que os grandes clubes apresentam dificuldades para superar adversários considerados tecnicamente inferiores. Esse entendimento, frequentemente associado aos chamados tropeços, costuma ser atribuído à pressão psicológica, ao relaxamento tático ou à própria imprevisibilidade do esporte. Contudo, raramente é confrontado de forma sistemática com dados históricos de desempenho.

Este TCC (Trabalho de Conclusão de Curso) investiga se a percepção de que grandes clubes brasileiros perdem pontos de forma recorrente contra adversários da zona de rebaixamento (Z4, os quatro últimos colocados ao final da temporada) se confirma nos dados históricos e, caso se confirme, quais fatores contextuais estão associados a esses resultados. Essa percepção é tratada aqui como uma ideia comum entre os torcedores, e não como algo medido por pesquisa de opinião: o que se analisa são os resultados das partidas. Neste trabalho, perder pontos significa empatar ou perder a partida.

Assim, por meio de uma abordagem baseada em dados, este trabalho tem como objetivo analisar o desempenho dos clubes pertencentes ao C13 (Clube dos 13)[2] no Campeonato Brasileiro Série A entre 2015 e 2025, com foco nos confrontos contra os times que terminaram a temporada no Z4. Embora a associação tenha sido dissolvida antes do período analisado, seus treze clubes continuam sendo utilizados aqui como critério histórico para representar os grandes clubes do país, por serem tradicionais e de grande projeção nacional. Dentro desse grupo, o Atlético Mineiro é analisado em maior detalhe, como estudo de caso, para verificar se os padrões observados no conjunto dos clubes se repetem em um único clube. Também se busca identificar fatores contextuais associados ao resultado dessas partidas, como a condição do mando de campo, o público presente, a idade dos jogadores, a altura dos titulares e o calendário, contribuindo tanto para a compreensão do fenômeno esportivo quanto para confrontar percepções consolidadas entre os torcedores com os dados.

Para isso, foram coletados dados de 4.898 registros de partidas e organizados em duas bases: uma que resume o desempenho de cada clube contra os times do Z4 e outra que registra cada partida individualmente. Com a base detalhada, foram construídas árvores de decisão para modelar o resultado das partidas (vitória, empate ou derrota), e a importância de cada variável, calculada a partir do ganho de informação, foi analisada no

[1]Por exemplo: Sofascore (`https://www.sofascore.com`), FBref (`https://fbref.com/`), Flashscore (`https://www.flashscore.com.br/`), oGol (`https://www.ogol.com.br/`)

[2]Associação criada em 1987 com o objetivo de representar os interesses políticos e comerciais dos principais clubes de futebol do Brasil. Inicialmente, era composta pelos treze clubes mais bem colocados no ranking da Confederação Brasileira de Futebol (CBF): Atlético Mineiro, Bahia, Botafogo, Corinthians, Cruzeiro, Flamengo, Fluminense, Grêmio, Internacional, Palmeiras, Santos, São Paulo e Vasco da Gama. A entidade foi posteriormente dissolvida em 2011.

conjunto dos clubes, nos jogos contra o Z4, nos jogos contra os demais adversários, no Atlético Mineiro e em cada temporada. Os resultados são interpretados como associações, e não como relações de causa e efeito.

Os resultados indicam que os clubes do *C13* venceram 55,7% das partidas contra os times do Z4, contra 38,1% diante dos demais adversários, com aproveitamentos entre 54,44% (Vasco da Gama) e 76,89% (Palmeiras). Nas árvores, a condição de mando de campo foi a variável mais associada ao resultado, entre as cinco mais importantes em 10 das 11 temporadas, e as características físicas dos elencos ganharam mais peso nos jogos contra o Z4. O desempenho preditivo das árvores foi modesto, com *accuracy* de 48,65% na árvore geral (*baseline* de 41,7%), o que mostra que os fatores contextuais disponíveis explicam apenas parte do resultado das partidas.

Este trabalho está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados ao tema; a Seção 3 descreve a metodologia, incluindo a coleta dos dados, as ferramentas utilizadas, o pré-processamento e o uso de árvores de decisão; a Seção 4 apresenta os resultados e a discussão; a Seção 5 conclui o trabalho, apresenta as limitações da abordagem e aponta direções para pesquisas futuras.

2. Trabalhos Relacionados

A identificação dos fatores que influenciam o resultado de partidas de futebol tem sido objeto de estudo em diferentes áreas, especialmente com o aumento da disponibilidade de dados esportivos. Nesse contexto, diversos trabalhos passaram a investigar a influência de variáveis como mando de campo, desempenho recente, características das equipes e fatores contextuais na ocorrência de vitórias, empates e derrotas.

O trabalho [de Carvalho 2022] propõe comparar o desempenho técnico do Clube Atlético Mineiro com base no local da partida e no formato do campeonato, utilizando dados estatísticos de 60 jogos da temporada de 2021 extraídos da plataforma *Sofascore*, a mesma utilizada neste trabalho. Os resultados indicam que a equipe manteve um padrão de jogo bem parecido e consistente em todas as competições, mas teve um desempenho superior ao atuar em casa. Sua pesquisa, contudo, é um estudo de caso restrito a um único clube e a uma única temporada, deixando de avaliar condições adversas dos times adversários que também podem influenciar nos resultados. Este trabalho avança nesse ponto ao analisar treze clubes ao longo de onze temporadas e ao incluir características dos adversários e do contexto das partidas, com foco nos fatores associados aos resultados contra os times que terminam a temporada na zona de rebaixamento.

Nesse sentido, pensando nos diversos motivos que influenciam o resultado de uma partida de futebol [Carlet 2015] propôs um estudo onde ele analisa o mando de campo do Campeonato Brasileiro de Futebol, buscando entender fatores como: a influência do fator local no resultado de uma partida de futebol; verificar qual o diferencial na conquista de um campeonato; e comparar o desempenho como mandante e visitante dos campeões e vice campeões. Para isso, o autor fez uma coleta de todos os resultados das edições de 1971 a 2013 e sumarizou os resultados gerais em duas tabelas: uma referente ao aproveitamento das equipes como mandante e visitante, e outra focada na comparação entre campeões e vice-campeões. Os resultados do autor mostram que dentre as 43 edições apenas em uma houve maior número de empates, enquanto em todas as outras restantes os mandantes tiveram mais vitórias.

De forma semelhante, [Nascimento and Silva 2020] também fizeram um estudo com o objetivo de comparar a vantagem de jogar em casa, mas com foco na comparação entre ligas de diferentes continentes. Nesse caso foram analisadas no total 6.000 partidas, sendo todas as partidas do Campeonato Brasileiro, *Premier League* e Superliga chinesa, nas condições de vitórias, empates e derrotas do período de 2012 a 2016. Os resultados também indicaram a vantagem de jogar em casa, mas, entre as três ligas, encontraram uma vantagem menor na liga chinesa, onde eles discutem que a razão é por ser uma liga emergente, com menor engajamento e adesão histórica de público nos estádios comparada às outras duas. Com base nisso, apesar dos avanços apresentados, observa-se que ambos analisaram apenas o resultado bruto, sendo ele vitória, derrota ou empate, e não exploraram outros fatores contextuais que também podem estar associados ao resultado do jogo. Este trabalho busca justamente ir além do resultado bruto, ao incluir variáveis como o público, a idade e a altura médias dos titulares.

Além dos estudos de mandante e visitante, [Rosa 2022] aplicou mineração de dados, com árvore de decisão e rede neural artificial, para prever quais times da Premier League terminariam na zona de classificação da *Champions League*. A partir de 3.800 partidas extraídas do site *FBref* por meio de *web scraping*, o autor testou o desempenho dos algoritmos *J48* (uma implementação de árvore de decisão) e *MultilayerPerceptron (MLP)* com conjuntos de 70 e 200 exemplos, com informações de temporadas entre 2011 e 2020. Com 70 exemplos, ambos os algoritmos tiveram previsibilidade de 70%, enquanto com 200 exemplos a previsibilidade do *J48* e do *MLP* foi respectivamente 94% e 99,5%, valores altos, mas obtidos com uma amostra pequena. Por outro lado, a replicação de métodos preditivos semelhantes em cenários emergentes esbarra em um obstáculo diferente: a escassez de dados.

Essa limitação é evidenciada por [Souza 2024], que, ao tentar prever resultados do Campeonato Brasileiro de Futebol Feminino, precisou recorrer a dados de ligas estrangeiras para compor seu conjunto de treinamento. Mesmo com essa adaptação, a autora esbarrou na imprevisibilidade inerente ao esporte e na ausência de histórico, alcançando uma acurácia de 60%, valor que a autora considera coerente com a imprevisibilidade característica do esporte. Tendo em vista essa limitação de dados, o presente artigo usa o recorte de 2015 a 2025, período em que já estão disponíveis as informações de todas as partidas e das métricas de desempenho das equipes.

Os estudos citados contribuem para a fundamentação da metodologia adotada neste trabalho. Os trabalhos de [Carlet 2015] e [Nascimento and Silva 2020], sobre o mando de campo, analisam apenas o resultado bruto das partidas, e o trabalho de [Rosa 2022] mostra o uso de árvores de decisão em dados do futebol. Com base nisso, a Árvore de Decisão foi escolhida como principal algoritmo de classificação: ela permite analisar atributos numéricos e categóricos (estes convertidos em variáveis indicadoras), como condição de mando, público, idade e altura médias dos titulares, e gera um modelo interpretável, o que facilita a explicação dos resultados obtidos. Nesse cenário, este trabalho aplica a modelagem computacional à inteligência esportiva, com o objetivo de identificar fatores associados ao desempenho das equipes de elite do futebol brasileiro contra os times da zona de rebaixamento. Entre os trabalhos revisados, não foram encontrados estudos que comparem o desempenho de vários clubes contra os times que terminam a temporada rebaixados e interpretem os fatores associados por meio de árvores de decisão.

É nessa combinação, de análise retrospectiva dos confrontos contra equipes rebaixadas, vários clubes e interpretação por árvores de decisão, que este trabalho busca contribuir.

3. Metodologia

Este trabalho classifica-se como uma pesquisa aplicada, pois tem como objetivo gerar conhecimentos no âmbito da inteligência esportiva. Quanto à abordagem do problema, caracteriza-se como uma pesquisa quantitativa, porque utiliza a mineração de dados e algoritmos de classificação para analisar grandes volumes de estatísticas históricas. Em relação aos procedimentos técnicos, a investigação apoia-se em pesquisa documental, por meio da coleta em bases de dados esportivas secundárias, e configura-se como uma análise dos clubes do Clube dos 13, com um estudo de caso centrado no Clube Atlético Mineiro.

A metodologia adotada, apresentada na Figura 1, é composta por um conjunto de etapas sequenciais, realizadas inicialmente com o intuito de estruturar e enriquecer a base de dados, para que, posteriormente, fossem realizadas a análise dessas informações e a respectiva avaliação da qualidade do modelo.

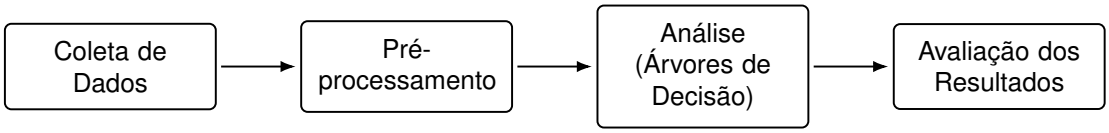


Figura 1. Fluxo metodológico da pesquisa.

O desenvolvimento foi organizado em quatro grandes etapas: coleta de dados, pré-processamento, análise por meio de árvores de decisão e avaliação dos resultados. A coleta e a estruturação dos dados, com enriquecimento progressivo das bases, resultaram em duas bases complementares, descritas adiante. O pré-processamento preparou essas bases para o uso nas árvores. A análise construiu árvores de decisão para o conjunto dos clubes, para os jogos contra os times rebaixados, para os jogos contra os demais adversários, para o Atlético Mineiro e para cada temporada. Por fim, a avaliação mediu o desempenho dos modelos e a importância das variáveis.

A escolha do Clube dos 13 (*C13*) para análise justifica-se como critério histórico para representar os grandes clubes do futebol brasileiro, por reunir clubes tradicionais e de grande projeção nacional. O grupo, formado em 1987, reúne treze clubes: Atlético Mineiro, Bahia, Botafogo, Corinthians, Cruzeiro, Flamengo, Fluminense, Grêmio, Internacional, Palmeiras, Santos, São Paulo e Vasco da Gama. Em cada temporada, foram considerados apenas os clubes do *C13* que disputaram a Série A. Utilizar o *C13* como universo amostral permite avaliar se o desempenho contra as equipes da zona de rebaixamento é uma particularidade de um único clube ou se aparece de forma semelhante entre os clubes tradicionais do país.

A primeira etapa consistiu na construção de duas bases de dados complementares. A primeira, em arquivo *csv*, consolida para cada clube do *C13* o total de vitórias, empates, derrotas, pontos perdidos, aproveitamento, média de pontos perdidos por jogo e desvio padrão da média de pontos perdidos por jogo entre as temporadas. Todos os resultados foram calculados exclusivamente para os confrontos contra os quatro clubes rebaixados ao final de cada edição do campeonato, considerando as partidas de ida e volta (oito jogos por clube em cada temporada). Quando o próprio clube foi um dos rebaixados naquela

temporada, foram contabilizados apenas os seis jogos contra os outros três clubes rebaixados. O desvio padrão é calculado sobre a média de pontos perdidos por jogo em cada temporada, para que temporadas com números diferentes de jogos possam ser comparadas. Essa visão agregada permite uma comparação direta entre os treze clubes ao longo do período analisado, respondendo à pergunta central do trabalho de forma sintética. Os valores de cada clube, com a explicação de cada coluna, estão na Tabela 3, apresentada nos Resultados.

A segunda base registra as partidas de forma individual, contendo as 38 rodadas de cada temporada para cada clube do *C13* que disputou a Série A naquele ano. Cada linha representa um jogo visto por um dos clubes e contém as seguintes informações: clube analisado, temporada, rodada, data, horário, dia da semana, mês, adversário, resultado, gols marcados, gols sofridos, condição de jogo (mandante ou visitante), árbitro, média de idade e desvio padrão de idade dos titulares de ambos os times, média de altura e desvio padrão de altura dos titulares de ambos os times, estádio e público presente. Como a base registra os jogos do ponto de vista de cada clube do *C13*, o número de linhas depende de quem está em campo. Quando dois clubes do *C13* se enfrentam (por exemplo, Atlético Mineiro e Palmeiras), o jogo aparece em duas linhas, uma para cada clube. Quando um clube do *C13* enfrenta um adversário de fora do grupo (por exemplo, Flamengo e Bragantino), o jogo aparece em uma linha, pois apenas o clube do *C13* faz parte da base. Assim, os 4.898 registros correspondem a 3.498 partidas únicas: 1.400 partidas entre clubes do *C13*, que aparecem em duas linhas, e 2.098 partidas contra adversários de fora do *C13*, que aparecem em uma. Essa base é o insumo principal para a etapa de modelagem da árvore de decisão, permitindo investigar quais variáveis contextuais estão associadas aos diferentes resultados.

Os códigos e conjuntos de dados desenvolvidos neste trabalho estão disponíveis publicamente em repositório aberto no GitHub[3].

3.1. Coleta de Dados

A coleta foi realizada entre 16 de maio e 19 de agosto de 2026. Embora o *Sofascore*[4] não disponibilize uma *API* pública oficial, o próprio site obtém seus dados por meio de requisições *HTTP* a endereços (*URLs*) internos. Esses endereços foram identificados com as ferramentas de desenvolvedor do navegador (*DevTools*), que mostram o tráfego de rede durante a navegação, técnica conhecida como engenharia reversa de *API* por observação de tráfego. Com base neles, foi possível acessar os dados de resultados, escalações, classificações e demais informações das partidas de forma automatizada, com o auxílio da biblioteca *Playwright* em *Python*. A coleta seguiu os mesmos princípios de acesso que qualquer navegador web realizaria ao navegar pelo site, com intervalos entre as requisições para minimizar o impacto nos servidores. Os dados foram utilizados exclusivamente para fins acadêmicos.

Durante a coleta, o *Sofascore* passou a bloquear o acesso a partir do endereço *IP* do computador utilizado. Depois de certo tempo de navegação, o site deixava de carregar e exibia uma mensagem de erro, mesmo quando era acessado normalmente pelo navegador,

[3] `https://github.com/AlvesLuan/tcc_scraper_sofascore`

[4] Plataforma e aplicativo de estatísticas e resultados esportivos em tempo real, criada pelos empreendedores croatas Zlatko Hrkać e Ivan Bešlić.

sem nenhuma coleta em andamento. Foram necessários alguns dias de investigação até identificar a causa. Para contornar o problema, foram adotadas quatro medidas:

- troca do navegador padrão do *Playwright* (*Chromium*) pelo *Firefox*;
- uso da biblioteca *Patchright*[5];
- aumento dos intervalos entre as requisições, de 3 para 10 segundos (foram testados também 8 segundos);
- fechamento e reabertura do navegador a cada temporada coletada, com pausa de 10 segundos, para limpar a sessão.

Essas medidas aumentaram o tempo de coleta de um clube, considerando as 11 temporadas, de cerca de 40 minutos a 1 hora para 2 horas e meia a 3 horas e meia. A coleta foi feita um clube por vez, em datas diferentes.

A coluna de público presente foi obtida de forma distinta. Por ser uma informação não disponível no Sofascore, recorreu-se ao site *FBref*[6], que registra o público de cada partida do Campeonato Brasileiro na variável *attendance*. As páginas foram salvas localmente no formato *HTML* e processadas com a biblioteca *BeautifulSoup*, que realizou a extração dos dados de cada temporada, identificando a rodada e público correspondente.

O cruzamento com a base detalhada foi feito pelo número da rodada dentro de cada temporada e clube. Jogos para os quais o *FBref* também não registrava público, bem como partidas sem dados de escalação no Sofascore, tiveram seus campos preenchidos manualmente após consultas específicas a fontes complementares, sendo elas o site da ESPN[7] e o GE[8].

A Tabela 1 resume os atributos da base detalhada, a fonte de cada um e o tipo de dado que ele representa. Na coleta, as colunas de idade, altura (e seus desvios padrão) e público foram registradas como texto, com vírgula decimal e separador de milhar, e as transformações necessárias para a construção das árvores, como a conversão para o formato numérico e a criação de variáveis indicadoras, são descritas no pré-processamento.

3.1.1. Ferramentas e tecnologias

O projeto foi desenvolvido integralmente em *Python*. As bibliotecas *Playwright* e *Patchright* foram utilizadas para a automação do navegador e a coleta de dados via HTTP, enquanto a *BeautifulSoup* foi empregada no *parsing*[9] de *HTML*, junto com as bibliotecas padrão para a manipulação de arquivos *CSV*. A limpeza e a organização dos dados foram feitas com a biblioteca *pandas*, a construção e a avaliação das árvores de decisão com a *scikit-learn* e a geração das figuras com a *matplotlib*.

[5]Versão modificada do *Playwright*, de código aberto, criada para reduzir sinais que permitem a um site identificar que o navegador está sendo controlado por um programa. Disponível em `https://github.com/Kaliiiiiiiiii-Vinyzu/patchright`.

[6]Site e base de dados online gratuito especializado em estatísticas detalhadas de futebol. Criado pela Sports Reference.

[7]https://www.espn.com.br/

[8]https://ge.globo.com/futebol/

[9]Processo de interpretar dados brutos e organizá-los em um formato que o computador consiga processar.

Tabela 1. Atributos da base detalhada, fonte de coleta e tipo de dado.

Atributo	Fonte	Tipo
Clube analisado	*Sofascore*	Categórico (texto)
Adversário	*Sofascore*	Categórico (texto)
Temporada	*Sofascore*	Inteiro
Rodada	*Sofascore*	Inteiro
Data	*Sofascore*	Data
Horário	*Sofascore*	Hora
Dia da semana	*Sofascore*	Categórico (texto)
Mês	*Sofascore*	Inteiro
Condição de jogo (mandante ou visitante)	*Sofascore*	Categórico (texto)
Resultado (vitória, empate ou derrota)	*Sofascore*	Categórico (texto)
Gols marcados	*Sofascore*	Inteiro
Gols sofridos	*Sofascore*	Inteiro
Árbitro	*Sofascore*	Categórico (texto)
Estádio	*Sofascore*	Categórico (texto)
Idade média dos titulares (equipe e adversário)	*Sofascore*	Real (contínuo)
Desvio padrão da idade dos titulares (equipe e adversário)	*Sofascore*	Real (contínuo)
Altura média dos titulares (equipe e adversário)	*Sofascore*	Real (contínuo)
Desvio padrão da altura dos titulares (equipe e adversário)	*Sofascore*	Real (contínuo)
Público presente	*FBref*	Inteiro

Os dados coletados foram armazenados em arquivos CSV, totalizando 4.898 registros na base detalhada, em que cada registro corresponde a uma partida do ponto de vista de um dos clubes analisados. A escolha do formato CSV se justifica pela compatibilidade com as ferramentas de análise utilizadas nas etapas seguintes.

3.2. Pré-processamento

Antes da construção das árvores, a base detalhada passou por uma etapa de preparação. A variável a ser prevista (variável-alvo) é o resultado da partida, categorizado em vitória, empate ou derrota, sempre do ponto de vista do clube analisado.

Algumas informações foram retiradas do conjunto de treino. Os gols marcados e sofridos foram excluídos por revelarem o resultado diretamente. O nome do clube e do adversário foram excluídos por identificarem os times, o que impediria generalizar os padrões para além de clubes específicos. O estádio também foi excluído, pois cada estádio está associado a um clube e, portanto, identificaria indiretamente os times envolvidos. O árbitro foi excluído por haver muitos nomes com poucas partidas cada, o que levaria a árvore a memorizar jogos em vez de identificar padrões gerais. A data e o horário foram excluídos por identificarem partidas específicas, e o mesmo vale para os desvios padrão de idade e de altura. Foram mantidas as informações de contexto da partida: temporada, rodada, mês, dia da semana, condição de jogo (mandante ou visitante), idade e altura médias dos titulares da equipe e do adversário e público presente.

Os campos numéricos (idade, altura e público) foram padronizados para o formato numérico. O público passou a ser registrado sem separador de milhar (por exemplo, 18298, e não 18.298), e as casas decimais de idade e altura passaram a ser registradas com ponto, e não com vírgula. Em seguida, foram removidos os registros com valores ausentes

nesses campos. Na base geral, essa etapa retirou 133 registros, sendo 58 sem dados de escalação e 75 sem público registrado, o que reduziu a base de 4.898 para 4.765 registros. Nas temporadas de 2020 e 2021, as partidas sem público (realizadas sem torcida em razão da pandemia do *COVID-19*) foram mantidas, com o público registrado como zero. As variáveis em formato de texto (condição de jogo e dia da semana) foram transformadas em variáveis indicadoras (*dummy*): cada categoria vira uma coluna com valores 0 ou 1, e uma delas é usada como referência e não gera coluna própria. Por exemplo, a coluna *condicao_Visitante* vale 1 quando o clube joga como visitante e 0 quando joga como mandante. Com isso, a base geral ficou com 15 atributos.

Dessa forma, os atributos considerados na árvore da base geral foram os 15 apresentados na Tabela 2. Nos demais recortes, o número de atributos pode ser menor quando algum dia da semana não ocorre nos jogos do recorte, e por isso não gera coluna (por exemplo, 14 atributos na árvore do Atlético Mineiro, que não disputou jogos às sextas-feiras na base).

Tabela 2. Atributos considerados na árvore da base geral.

Tipo	**Atributos**
Numéricos (8)	*temporada*, *rodada*, *mes*, *idade_media_titular_time*, *altura_media_titular_time*, *idade_media_titular_adv*, *altura_media_titular_adv*, *publico*
Dia da semana (6)	*dia_semana_Segunda*, *dia_semana_Terça*, *dia_semana_Quarta*, *dia_semana_Quinta*, *dia_semana_Sexta*, *dia_semana_Sábado*
Condição de jogo (1)	*condicao_Visitante*

As árvores foram construídas para cinco recortes da base: o conjunto dos clubes do *C13*, os jogos do *C13* contra os quatro clubes rebaixados ao final de cada temporada (Z4), os jogos contra os demais adversários (todos os que não terminaram a temporada no Z4), as partidas do Atlético Mineiro e cada uma das temporadas, de 2015 a 2025.

3.3. Árvore de Decisão

A Árvore de Decisão é um algoritmo de aprendizado supervisionado que organiza o processo de classificação em uma estrutura semelhante a um fluxograma. Em cada etapa, o algoritmo utiliza uma regra de decisão para separar os dados até chegar a uma classificação final, facilitando a identificação das variáveis que mais influenciam o resultado. A Figura 2 apresenta um exemplo simplificado dessa estrutura.

A principal vantagem desse algoritmo é a geração de modelos interpretáveis, característica essencial para este trabalho, cujo objetivo é compreender os fatores associados ao resultado das partidas. Foi utilizada a biblioteca *scikit-learn* [Pedregosa et al. 2011], em *Python*, que permite controlar os parâmetros do modelo e calcular métricas de avaliação.

Em todas as árvores foi utilizado o critério *entropy*, baseado no ganho de informação [Quinlan 1986]. Esse critério mede o quanto um grupo de partidas está misturado entre vitórias, empates e derrotas, e, a cada divisão, o algoritmo escolhe a regra que mais

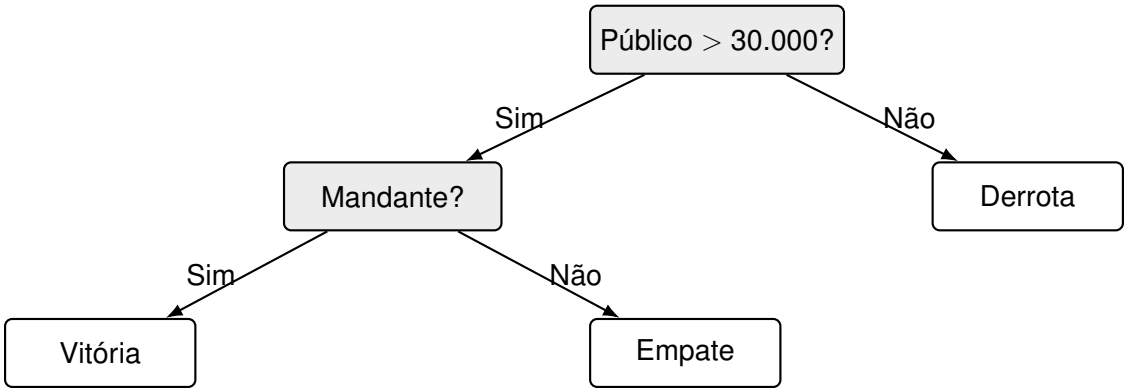


Figura 2. Exemplo de Árvore de Decisão.

reduz essa mistura. Os resultados indicam quais variáveis estão mais associadas ao resultado das partidas, sem que isso signifique, por si só, uma relação de causa e efeito.

3.3.1. Escolha da configuração e validação cruzada

Para manter a interpretabilidade das árvores geradas, a profundidade máxima (*max_depth*) foi definida antes da busca, em 5 níveis nas árvores apresentadas nos Resultados, tendo sido testadas também árvores de 10 níveis para comparação. Os demais parâmetros foram escolhidos por meio do *GridSearchCV*[10], que testou o número mínimo de partidas em cada folha da árvore (*min_samples_leaf*: 1, 5, 10 e 20) e o número mínimo de partidas para que um grupo possa ser dividido (*min_samples_split*: 2, 10 e 20). Na busca, as combinações foram comparadas pela *balanced accuracy* (definida adiante), com a mesma validação cruzada descrita a seguir, e foi escolhida a de melhor resultado.

Para avaliar os modelos, foi utilizada a validação cruzada estratificada[11], com 5 partes (*folds*), embaralhamento prévio dos dados e semente fixa (*random_state*=42). Como, na base detalhada, um jogo entre dois clubes do *C13* aparece em duas linhas, a validação foi agrupada por partida (*StratifiedGroupKFold*): cada partida é identificada pela temporada, pela rodada e pelos dois clubes, e as duas linhas de uma mesma partida ficam sempre na mesma parte. Assim, o modelo não é testado em uma partida que já viu no treino pelo ponto de vista do outro clube. Dessa forma, cada registro é testado uma única vez, por um modelo que não o viu durante o treino. As métricas de desempenho são calculadas a partir dessas previsões, e o desvio padrão entre as partes indica o quanto o resultado varia de uma rodada para outra.

Foram testadas, antes da adoção do agrupamento por partida, duas configurações de validação cruzada, com 5 e 10 *folds*. A diferença entre elas foi inferior a um ponto percentual na maioria das métricas, mas o uso de 10 *folds* apresentou maior desvio padrão entre as partes, indicando maior variação entre as rodadas. Assim, optou-se, de modo geral, pela utilização de 5 *folds*.

[10]Método que testa diferentes configurações do modelo e identifica aquelas que apresentam melhor desempenho.

[11]Técnica que divide os dados em partes (*folds*), mantendo em cada uma a mesma proporção de vitórias, empates e derrotas. Em cada rodada, uma parte é usada para teste e as demais para treino.

3.3.2. Métricas de avaliação

O desempenho dos modelos é medido por cinco métricas. A *accuracy* é a proporção de partidas classificadas corretamente. A *balanced accuracy* calcula o acerto de cada resultado separadamente e tira a média, dando o mesmo peso a vitórias, empates e derrotas. O *F1-macro* resume, também com o mesmo peso para as três classes, a relação entre a precisão e o *recall*. A precisão é a proporção das previsões de uma classe que estavam corretas, e o *recall* é a proporção das partidas de uma classe que o modelo conseguiu identificar. Como referência, é usado o *baseline*, que é a *accuracy* obtida por um modelo que prevê sempre a classe mais frequente de cada recorte, sem usar nenhuma variável. Por exemplo, se 40% das partidas de um recorte terminam em vitória e essa é a classe mais frequente, um modelo que previsse vitória em todos os jogos acertaria 40%. Assim, o *baseline* indica o que se consegue sem aprender nada com os dados, e a *accuracy* de uma árvore só representa um ganho quando o supera.

As árvores mostradas nas figuras da seção de Resultados são treinadas com todos os dados do seu recorte, e delas vêm a estrutura e a importância das variáveis. O desempenho informado vem sempre da validação cruzada.

3.4. Importância das variáveis

A importância de cada variável indica o quanto ela contribuiu para organizar as partidas dentro da árvore. No *scikit-learn*, ela é calculada somando o ganho de informação de todas as divisões em que a variável foi utilizada, dando mais peso às divisões que envolvem mais partidas. Os valores são então ajustados para que a soma de todas as variáveis seja igual a 1. Assim, uma variável com importância 0,50, por exemplo, responde por metade de toda a redução de mistura obtida pela árvore.

Como os valores somam 1, a importância de uma variável também depende do número de divisões da árvore: quanto mais divisões, menor a parcela de cada variável. Em 2024, por exemplo, a importância da condição de jogo (*condicao_Visitante*) foi de 0,1687 com *max_depth*=5 e de 0,0688 com *max_depth*=10, nos mesmos dados. A variável foi usada uma única vez, na raiz, nas duas árvores, e o efeito do mando em 2024 não mudou (diferença de 22,4 pontos percentuais entre a taxa de vitórias de mandante e de visitante, próxima da média da série). A queda se deve ao maior número de divisões da árvore mais profunda. Por esse motivo, as comparações de importância entre recortes e entre temporadas foram feitas apenas com árvores de mesma profundidade, e a análise ano a ano usa *max_depth*=5.

3.4.1. Ajuste de pesos entre as classes

Em alguns recortes foram treinadas duas versões da árvore: uma sem ajuste e outra com *class_weight*="balanced"[12], aplicado na escolha da configuração, na avaliação e na árvore final. A versão balanceada foi adotada como principal apenas no recorte contra o Z4, em que a versão sem ajuste previa quase sempre Vitória, enquanto a balanceada distribuiu melhor os acertos entre as três classes. Na árvore geral e na do Atlético Mineiro, a versão

[12] Ajuste que atribui maior peso aos erros cometidos nas classes menos frequentes, evitando que o modelo priorize a classe majoritária.

sem ajuste foi mantida como principal. As duas versões são apresentadas nos Resultados, para comparação.

4. Resultados e Discussão

Esta seção apresenta os resultados obtidos a partir da coleta, do processamento e da análise das 4.898 registros de partidas disputadas nas temporadas do Campeonato Brasileiro Série A entre 2015 e 2025. Após a aplicação dos critérios de filtragem e classificação estabelecidos na metodologia, os dados foram analisados por meio da árvore de decisão, buscando identificar padrões e fatores associados ao desempenho das equipes nas partidas avaliadas. Os resultados são apresentados com o intuito de evidenciar as principais relações encontradas no conjunto de dados e o desempenho das equipes diante dos diferentes grupos de adversários considerados no estudo.

Os procedimentos de construção e avaliação das árvores, como o critério *entropy*, a escolha da configuração dos modelos e a validação cruzada, foram apresentados na Metodologia, e as configurações utilizadas são apresentadas nas respectivas subseções. Os resultados estão organizados na seguinte ordem: i) árvore geral do clube dos 13; ii) desempenho dos clubes contra os times do Z4 e comparação com os demais adversários; iii) árvore referente aos jogos contra equipes do Z4; iv) árvore referente aos jogos contra os demais adversários; v) árvore do Atlético Mineiro; e vi) análise da importância das variáveis ao longo das temporadas.

4.1. Árvore de decisão do Clube dos 13

Para o conjunto de dados do Clube dos 13, após a etapa de limpeza, foram considerados 4.765 registros e 15 atributos para a construção da árvore de decisão. A configuração selecionada foi *max_depth*=5, *min_samples_leaf*=10 e *min_samples_split*=2, utilizando o critério *entropy*. A avaliação foi realizada por meio de validação cruzada estratificada, agrupada por partida, com 5 *folds*.

A Figura 3 apresenta a árvore de decisão obtida para os dados analisados. Observa-se que a primeira divisão do modelo ocorre a partir da condição de mando de campo, representada pela variável condicao de jogo (conforme a arvore), que também apresentou a maior importância entre os atributos, com valor de 0,5748. Esse resultado é coerente com os estudos sobre mando de campo anteriormente citados [Carlet 2015, Nascimento and Silva 2020], que encontraram maior número de vitórias dos mandantes. Em seguida, destacam-se a idade média dos titulares da equipe, com importância de 0,1148, o público da partida, com 0,1125, e a altura média dos titulares da equipe, com 0,0839. As demais variáveis apresentaram valores inferiores a 0,05, indicando menor participação na construção das decisões do modelo.

Quanto ao desempenho da classificação, a árvore obteve *accuracy* de 48,65%, superior ao *baseline* de 41,7%, com *balanced accuracy* de 44,13% e *F1-macro* de 38,86%. Esses resultados indicam que, embora a árvore tenha apresentado desempenho superior à referência, sua capacidade de distinguir corretamente entre Vitória, Empate e Derrota foi limitada.

A análise das classes mostra que o modelo apresentou desempenho superior na identificação de vitórias e derrotas. Para a classe Vitória, foram obtidos precisão de 52,6% e *recall* de 68,1%, enquanto, para a classe Derrota, os valores foram de 44,8% e 61,3%,

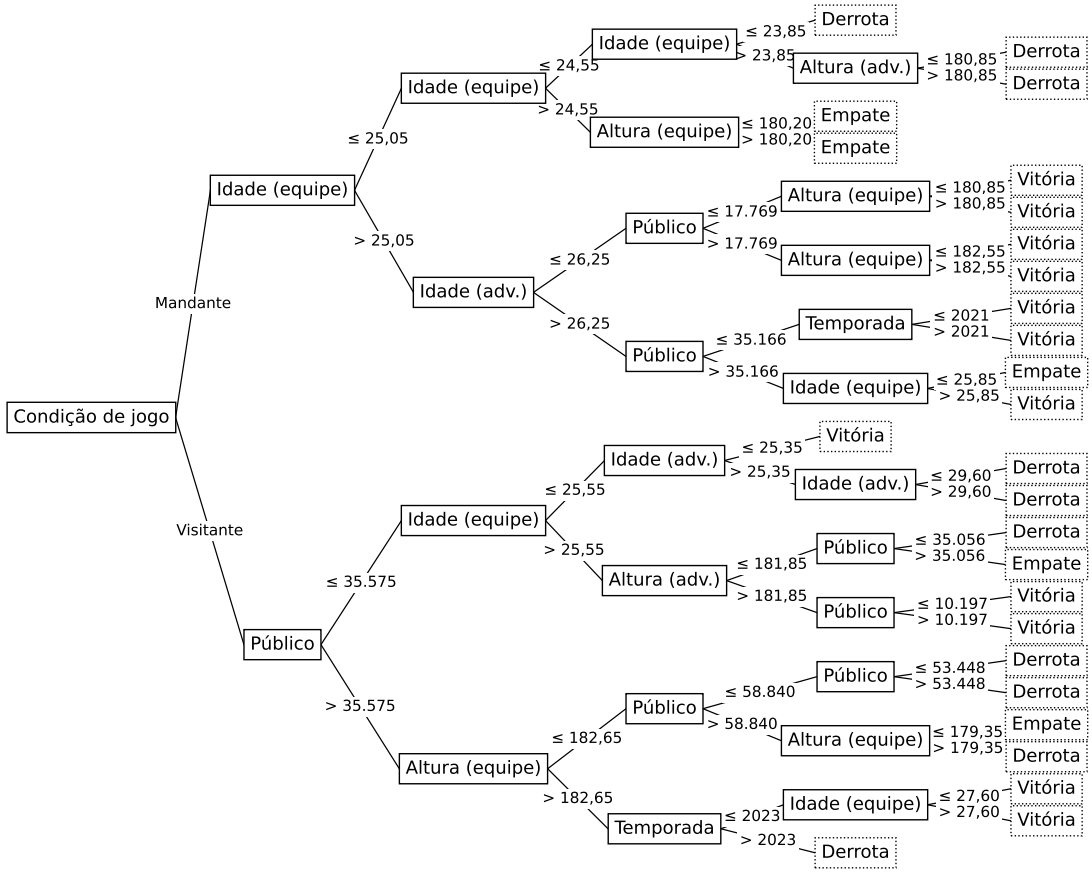


Figura 3. Árvore de decisão do Clube dos 13. As caixas com borda contínua indicam a variável testada, e as caixas pontilhadas, a classe prevista. (adv. = adversário)

respectivamente. Já a classe Empate apresentou precisão de 31,1% e *recall* de apenas 3,0%, evidenciando a dificuldade do modelo em reconhecer esse tipo de resultado. Essa dificuldade em reconhecer empates também foi observada por [Souza 2024], cujo melhor modelo acertou apenas 35% dessa classe.

Esse comportamento também é observado na matriz de confusão, na qual 1.351 das 1.985 vitórias e 929 das 1.515 derrotas foram classificadas corretamente. Entre os 1.265 empates presentes na base, apenas 38 foram identificados corretamente. Assim, a árvore apresentou maior capacidade de classificação das partidas que terminaram em Vitória ou Derrota, enquanto os empates foram frequentemente classificados como uma das outras duas categorias. Esse padrão será posteriormente comparado com os resultados das demais árvores, permitindo verificar se a dificuldade na identificação dos empates se mantém nos diferentes grupos analisados.

4.2. Desempenho do Clube dos 13 contra os times do Z4

A base agregada, descrita na Metodologia, reúne os resultados acumulados de cada clube do *C13* nos confrontos contra os times do Z4 entre 2015 e 2025. A Tabela 3 apresenta os clubes ordenados do maior para o menor valor de média de pontos perdidos por jogo, o

que indica quais times mais desperdiçaram pontos contra adversários rebaixados ao longo do período. O Vasco da Gama foi o clube que mais perdeu pontos, com 1,37 ponto por jogo e aproveitamento de 54,44%, seguido de Cruzeiro (1,24), Santos e São Paulo (1,22 cada). No extremo oposto, Palmeiras (0,69 ponto por jogo e aproveitamento de 76,89%) e Flamengo (0,76 e 74,62%) foram os que menos perderam pontos, cerca de metade da perda do Vasco. Os demais clubes ficaram entre 0,95 e 1,18 ponto perdido por jogo.

Tabela 3. Desempenho acumulado dos clubes do *C13* contra times do Z4 na Série A (2015–2025), ordenado pela média de pontos perdidos por jogo.

Clube	Vit.	Emp.	Der.	Jogos	Pontos perdidos	Aprov. (%)	Média de pontos perdidos/jogo	Desvio padrão da média por jogo por temporada
Vasco	27	17	16	60	82	54,44	1,37	0,28
Cruzeiro	30	19	13	62	77	58,60	1,24	0,44
São Paulo	43	28	17	88	107	59,47	1,22	0,27
Santos	39	22	17	78	95	59,40	1,22	0,30
Bahia	31	20	11	62	73	60,75	1,18	0,24
Botafogo	35	23	12	70	82	60,95	1,17	0,62
Fluminense	48	22	18	88	98	62,88	1,11	0,31
Internacional	44	21	13	78	81	65,38	1,04	0,38
Atlético-MG	50	23	15	88	91	65,53	1,03	0,35
Corinthians	49	27	12	88	90	65,91	1,02	0,43
Grêmio	46	22	10	78	74	68,38	0,95	0,35
Flamengo	60	17	11	88	67	74,62	0,76	0,41
Palmeiras	64	11	13	88	61	76,89	0,69	0,63

Na Tabela 3, *Jogos* (J) é o total de partidas do clube contra times do Z4 no período, e varia entre os clubes conforme o número de temporadas disputadas na Série A. Os *pontos perdidos* (PP) somam 3 por derrota (D) e 2 por empate (E):

$$PP = 3D + 2E.$$

O *aproveitamento* é a porcentagem de pontos conquistados em relação ao total possível, calculada a partir do número de vitórias (V) e de empates:

$$\text{Aproveitamento} = \frac{3V + E}{3J} \times 100.$$

A *média de pontos perdidos por jogo*, dada por PP/J, permite comparar clubes com números diferentes de jogos, e o *desvio padrão* mostra o quanto essa média varia de uma temporada para outra.

Os resultados da Tabela 3 mostram diferenças importantes no desempenho dos clubes do *C13* contra equipes da zona de rebaixamento. O Palmeiras obteve o melhor aproveitamento (76,89%), perdendo, em média, apenas 0,69 pontos por jogo. Em seguida aparece o Flamengo, com aproveitamento de 74,62% e média de 0,76 pontos perdidos por partida. Ambos se destacam em relação aos demais clubes, já que o terceiro colocado,

Grêmio, apresenta aproveitamento de 68,38%. Por outro lado, o Vasco da Gama registrou o menor aproveitamento (54,44%), seguido por Cruzeiro (58,6%) e Santos (59,4%).

Além do aproveitamento, o desvio padrão da média de pontos perdidos por jogo em cada temporada permite avaliar a regularidade do desempenho de cada clube. Como a média é calculada por jogo, temporadas com números diferentes de jogos (seis, nos anos em que o clube foi rebaixado) podem ser comparadas. Embora o Palmeiras apresente o melhor aproveitamento geral, também possui o maior desvio padrão da tabela (0,63), seguido de perto pelo Botafogo (0,62), o que indica maior variação de desempenho entre as temporadas. Por outro lado, o Bahia, apesar do aproveitamento intermediário de 60,75%, registrou o menor desvio padrão (0,24), seguido por São Paulo (0,27) e Vasco da Gama (0,28), o que sugere um desempenho mais consistente ao longo dos anos. Esses resultados mostram que um alto aproveitamento não significa, necessariamente, maior regularidade.

O Atlético Mineiro, clube do estudo de caso, ocupa uma posição intermediária entre os clubes analisados, com aproveitamento de 65,53% contra equipes do Z4. Seu desempenho é bastante próximo ao do Internacional (65,38%) e ao do Corinthians (65,91%), indicando que o clube não se destaca nem entre os melhores nem entre os piores resultados observados.

Para verificar se esse desempenho é próprio dos jogos contra os rebaixados, a taxa de vitórias de cada clube contra o Z4 foi comparada à taxa contra os demais adversários, isto é, todos os que não terminaram a temporada entre os quatro últimos. Considerando todos os jogos da base (1.016 contra o Z4 e 3.882 contra os demais, que somam os 4.898 registros), os clubes do *C13* venceram 55,7% dos jogos contra o Z4 e 38,1% contra os demais adversários, uma diferença de cerca de 18 pontos percentuais. A taxa de empates é praticamente a mesma nos dois grupos (26,8% e 26,5%), e a diferença está na troca de derrotas (17,5% contra o Z4 e 35,5% contra os demais) por vitórias. Como mostra a Tabela 4, todos os treze clubes venceram proporcionalmente mais contra o Z4 do que contra os demais adversários, com diferenças entre 11,9 pontos percentuais (São Paulo) e 23,9 (Palmeiras). O Atlético Mineiro venceu 56,8% dos jogos contra o Z4 e 41,0% contra os demais adversários, uma diferença de 15,8 pontos percentuais.

Entre os demais adversários estão os outros clubes do *C13*, o que reduz a taxa de vitórias desse grupo, já que, nesses confrontos, a vitória de um clube é a derrota de outro. Contra os adversários de fora do *C13* que não terminaram no Z4, a taxa de vitórias foi de 41,9% (1.248 jogos), contra 36,3% (2.634 jogos) contra os próprios clubes do grupo. Mesmo na comparação com os adversários de fora do *C13*, a taxa contra o Z4 permanece 13,8 pontos percentuais acima.

4.3. Árvore de decisão do Clube dos 13 contra times do Z4

Nesta etapa, foram consideradas apenas as partidas em que equipes do Clube dos 13 enfrentaram clubes que terminaram a temporada na zona de rebaixamento (Z4). Quando o próprio clube observado foi rebaixado na temporada, foram consideradas apenas as partidas contra os outros três clubes rebaixados. Após a limpeza, foram considerados 984 registros e 15 atributos. A distribuição das classes é mais desbalanceada do que na base geral: 550 vitórias (55,9%), 263 empates (26,7%) e 171 derrotas (17,4%). Consequentemente, o *baseline* deste recorte é de 55,9%, valor consideravelmente superior aos 41,7% observados na árvore geral.

Tabela 4. Taxa de vitórias de cada clube do *C13* contra o Z4 e contra os demais adversários (2015–2025), ordenada pela taxa contra o Z4.

Clube	Jogos vs Z4	Vitórias vs Z4 (%)	Jogos vs demais	Vitórias vs demais (%)	Diferença (p.p.)
Palmeiras	88	72,7	330	48,8	23,9
Flamengo	88	68,2	330	48,8	19,4
Grêmio	78	59,0	302	38,1	20,9
Atlético-MG	88	56,8	329	41,0	15,8
Internacional	78	56,4	302	38,1	18,3
Corinthians	88	55,7	330	36,7	19,0
Fluminense	88	54,5	328	35,1	19,5
Santos	78	50,0	302	37,1	12,9
Botafogo	70	50,0	271	36,9	13,1
Bahia	62	50,0	242	30,2	19,8
São Paulo	88	48,9	330	37,0	11,9
Cruzeiro	62	48,4	242	32,6	15,7
Vasco da Gama	60	45,0	244	28,3	16,7
Total	1.016	55,7	3.882	38,1	17,6

Diante desse desbalanceamento, foram treinadas duas versões da árvore: uma sem ajuste de pesos e outra com *class_weight*="balanced". Na versão balanceada, o algoritmo dá mais peso às partidas de resultados menos frequentes. Como as vitórias são bem mais numerosas que os empates e as derrotas, sem esse ajuste a árvore tende a favorecer a previsão de vitória. Com o ajuste, um erro em uma derrota, que é o resultado mais raro contra o Z4, passa a custar mais do que um erro em uma vitória, e as três classes passam a ter importância parecida na construção da árvore. Ambas utilizaram o critério *entropy*, *max_depth*=5 e validação cruzada estratificada, agrupada por partida, com 5 *folds*. Nas duas versões, a configuração selecionada teve *min_samples_leaf*=1, com *min_samples_split*=20 na versão sem ajuste e *min_samples_split*=10 na versão balanceada. A Tabela 5 compara o desempenho das duas versões com o da árvore geral.

Tabela 5. Desempenho da árvore geral e das duas versões da árvore contra times do Z4.

Métrica	Geral	Z4 sem peso	Z4 balanceada
Registros	4.765	984	984
Baseline	41,7%	55,9%	55,9%
Accuracy	48,65%	52,44%	38,52%
Balanced accuracy	44,13%	35,71%	36,57%
F1-macro	38,86%	32,95%	35,30%
Recall – Derrota	61,3%	2,3%	29,8%
Recall – Empate	3,0%	22,4%	38,8%
Recall – Vitória	68,1%	82,4%	41,1%
Desvio-padrão da *accuracy* entre *folds*	0,007	0,028	0,053

Como podemos observar, a versão sem ajuste de pesos apresentou *accuracy* de 52,44%, valor aparentemente superior ao da versão balanceada. Entretanto, esse resultado ainda ficou abaixo do *baseline* de 55,9% e foi obtido às custas de um comportamento

muito concentrado na classe Vitória: o modelo identificou corretamente 82,4% das vitórias (453 de 550), mas apenas 2,3% das derrotas (4 de 171) e 22,4% dos empates (59 de 263). Das 984 partidas, 774 (78,7%) foram classificadas como Vitória. Na árvore treinada com todos os dados, 13 das 19 folhas indicam Vitória, 3 indicam Derrota e 3 indicam Empate. Em outras palavras, a árvore aprendeu a prever Vitória na grande maioria dos casos, o que maximiza o acerto bruto, mas não contribui para identificar os fatores associados aos demais resultados, que são justamente os mais informativos neste recorte, por representarem os jogos em que o clube do Clube dos 13 não confirma o favoritismo.

A versão balanceada, por sua vez, apresentou *recall* de 29,8% para Derrota (51 de 171), 38,8% para Empate (102 de 263) e 41,1% para Vitória (226 de 550). Além disso, a versão balanceada obteve maior *balanced accuracy* (36,57% contra 35,71%) e maior *F1-macro* (35,30% contra 32,95%), embora a diferença nessas duas métricas seja pequena, sendo a mais evidente a da classe Derrota (*recall* de 29,8% contra 2,3%). Por esse motivo, e considerando que o objetivo do trabalho é compreender os fatores associados a cada tipo de resultado, e não maximizar o número bruto de acertos, esta foi a versão adotada como principal neste recorte.

Esse resultado, contudo, deve ser interpretado com cautela. A *accuracy* de 38,52% é inferior ao *baseline*, e as precisões obtidas (19,2% para Derrota e 27,6% para Empate) ficam próximas das proporções dessas classes na base (17,4% e 26,7%), enquanto a de Vitória (64,8%) fica um pouco acima da proporção da classe (55,9%). Isso indica que o modelo balanceado passou a apontar Derrota e Empate com maior frequência, mas com ganho limitado em relação ao acaso, principalmente para a classe Empate, cuja precisão é praticamente igual à proporção da classe. O desvio-padrão da *accuracy* entre os *folds* (0,053) também foi maior que o da árvore geral (0,007), refletindo o menor tamanho da amostra.

A Figura 4 apresenta a árvore da versão balanceada, treinada com todos os dados.

Quanto à importância das variáveis, a altura média dos titulares da equipe (0,1771) e a condição de mando (0,1769) ficaram praticamente empatadas nas primeiras posições, seguidas pela idade média dos titulares do adversário (0,1348), pela altura média dos titulares do adversário (0,1044) e pela idade média dos titulares da equipe (0,1014). A temporada (0,0927) e a rodada (0,0919) vêm logo depois. Embora o mando seja a primeira divisão da árvore, sua parcela é bem menor do que na árvore geral (0,5748), e a importância se distribui entre mais variáveis. Como as duas árvores foram treinadas com a mesma profundidade, a comparação das importâncias é possível, embora a diferença de tamanho amostral, o ajuste de pesos e a configuração da árvore (mais ramificada neste recorte, com *min_samples_leaf*=1) exijam cautela. Uma possível leitura é que, ao enfrentar equipes que terminam a temporada na zona de rebaixamento, a vantagem do mando de campo perde parte de sua capacidade de distinguir os resultados, deixando as características físicas das equipes e o momento da competição mais evidentes. Esta, porém, é uma hipótese que não foi testada diretamente neste trabalho. A versão sem ajuste de pesos apresentou composição parecida (altura média dos titulares da equipe com 0,2564, mando com 0,2480 e altura média dos titulares do adversário com 0,2091), o que sugere que a menor concentração da importância no mando de campo, em relação à árvore geral, não decorre apenas do balanceamento.

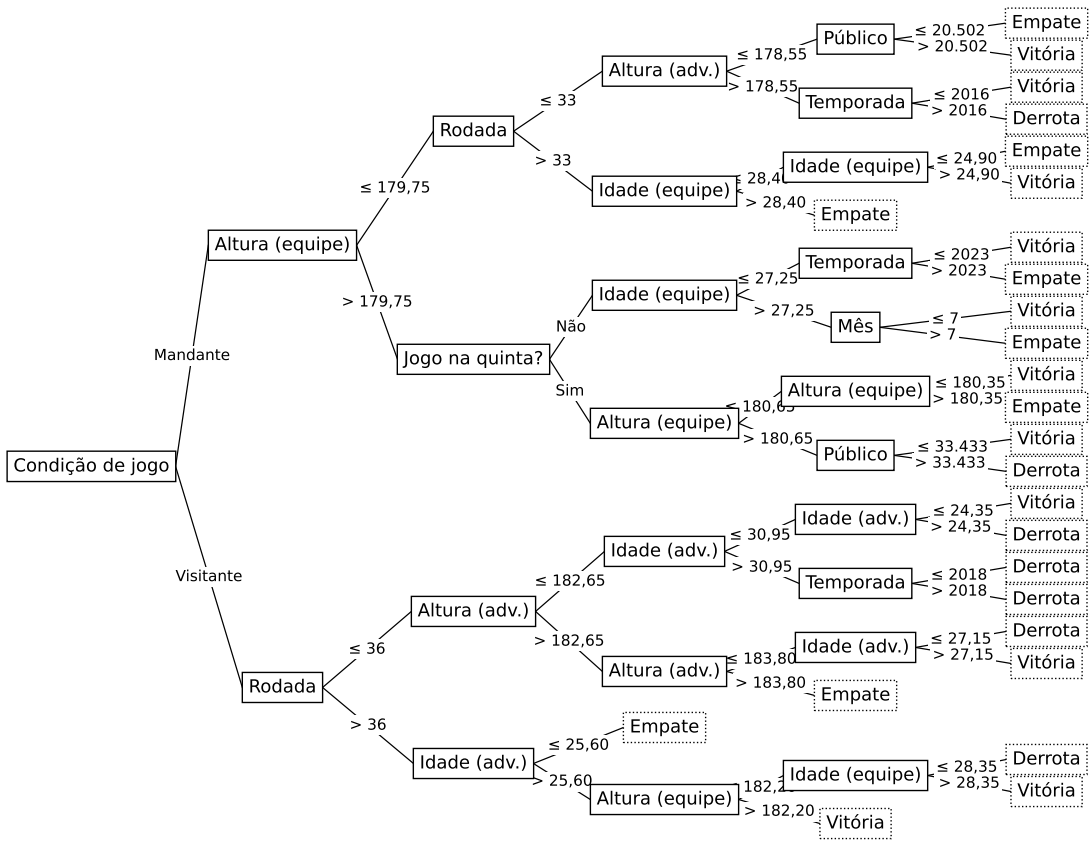


Figura 4. Árvore de decisão do Clube dos 13 contra os clubes do Z4 (versão com balanceamento de classes). As caixas com borda contínua indicam a variável testada, e as caixas pontilhadas, a classe prevista. (adv. = adversário)

Na estrutura da árvore, após a divisão pelo mando, o clube que joga em casa é dividido pela altura média dos titulares da equipe (179,75 cm), e o que joga fora de casa, pela rodada (36,5). Considerando as 26 folhas da árvore, as que correspondem a jogos em casa indicam mais Vitória (7) e Empate (6) do que Derrota (2), enquanto as de jogos fora de casa indicam mais Derrota (5), com 4 de Vitória e 2 de Empate. A altura média dos titulares aparece em diversos pontos de divisão, tanto da equipe quanto do adversário, o que contribui para o seu peso na importância total. Como a altura média de um elenco tende a variar pouco ao longo de uma mesma temporada, essa variável pode estar refletindo características particulares de cada clube e não um efeito direto da estatura sobre o resultado, o que reforça a necessidade de interpretá-la como associação e não como causa. A variável *rodada* aparece em divisões nas rodadas finais (acima de 33,5 e de 36,5), mas esses ramos provavelmente envolvem poucas partidas, de modo que a interpretação, por exemplo, de um efeito de fim de campeonato, é apenas uma hipótese. O público aparece em duas divisões, em 20.503 e em 33.433 pessoas, ambas na parte da árvore em que o clube joga em casa, e a interpretação desses limiares não foi investigada. A temporada aparece em três divisões (2016, 2018 e 2023) e, como em outros recortes, pode estar refletindo o período dos clubes e não um fator independente, o que também não foi verificado. Em uma divisão (a da temporada em 2018, na parte em que o clube

joga fora de casa), os dois lados terminam na mesma classe (Derrota), o que significa que a variável reduziu a mistura entre as classes sem alterar a previsão final. Por fim, como o balanceamento de classes altera a classe atribuída às folhas, a leitura das previsões em cada ramo também deve ser feita com cautela.

Em comparação com a árvore geral, portanto, o recorte contra times do Z4 apresenta maior dificuldade de classificação, menor estabilidade entre os *folds* e uma importância mais distribuída entre as variáveis. A dificuldade em reconhecer empates, observada na árvore geral, diminuiu na versão balanceada (*recall* de 38,8%, contra 3,0%), em parte por causa do ajuste de pesos, que a árvore geral não utiliza. No entanto, esse aumento veio acompanhado de queda na *accuracy* e de precisão (27,6%) próxima à proporção da própria classe (26,7%), não indicando, portanto, que os empates passaram a ser efetivamente explicados pelos atributos utilizados.

4.4. Árvore de decisão do Clube dos 13 contra os demais adversários

Para servir de comparação ao recorte do Z4, foi construída uma árvore com as partidas do Clube dos 13 contra os adversários que não terminaram a temporada na zona de rebaixamento. Esse recorte inclui também os confrontos entre clubes do grupo, que aparecem em duas linhas e foram mantidos juntos na validação cruzada agrupada por partida. Após a limpeza, foram considerados 3.781 registros e 15 atributos, cerca de 79% da base geral. A distribuição das classes é mais equilibrada do que no Z4: 1.435 vitórias (38,0%), 1.344 derrotas (35,5%) e 1.002 empates (26,5%), de modo que o *baseline* é de 38,0%. Foi utilizada a versão sem ajuste de pesos, com critério *entropy*, *max_depth*=5 e validação cruzada estratificada, agrupada por partida, com 5 *folds*. A configuração selecionada foi *min_samples_leaf*=1 e *min_samples_split*=10.

A árvore obteve *accuracy* de 49,03%, acima do *baseline*, com *balanced accuracy* de 44,72% e *F1-macro* de 39,25%, valores próximos aos da árvore geral (48,65%, 44,13% e 38,86%), o que é esperado, já que este recorte reúne cerca de 79% dos registros daquela base. O desvio-padrão da *accuracy* entre os *folds* foi de 0,007. A classe Derrota teve precisão de 47,9% e *recall* de 66,0% (887 de 1.344), e a classe Vitória, precisão de 51,1% e *recall* de 65,6% (941 de 1.435). A classe Empate repetiu a dificuldade observada na árvore geral: *recall* de 2,6% (26 de 1.002) e precisão de 28,9%, com apenas 90 dos 3.781 jogos classificados como Empate. Em contraste, no recorte do Z4 a *accuracy* ficou abaixo do *baseline* nas duas versões.

A Figura 5 apresenta a árvore treinada com todos os dados do recorte. A condição de mando foi a variável mais importante, com 0,6104, e a primeira divisão da árvore, seguida pela idade média dos titulares do adversário (0,0880), pelo público (0,0739), pela rodada (0,0734) e pela idade média dos titulares da equipe (0,0580). As alturas médias tiveram importâncias baixas (0,0446 para a equipe e 0,0335 para o adversário), diferentemente do recorte do Z4, em que a altura média dos titulares da equipe esteve entre as variáveis mais importantes nas duas versões. Como as árvores têm a mesma profundidade, a comparação das importâncias é possível, e a mais direta é com a versão do Z4 sem ajuste de pesos, que também não usa balanceamento: nela, o mando teve 0,2480, contra 0,6104 aqui. Isso é compatível com a hipótese levantada na seção anterior, de que contra equipes rebaixadas o mando de campo perde parte de sua capacidade de distinguir os resultados, mas ela continua sendo uma hipótese, pois os dois recortes têm

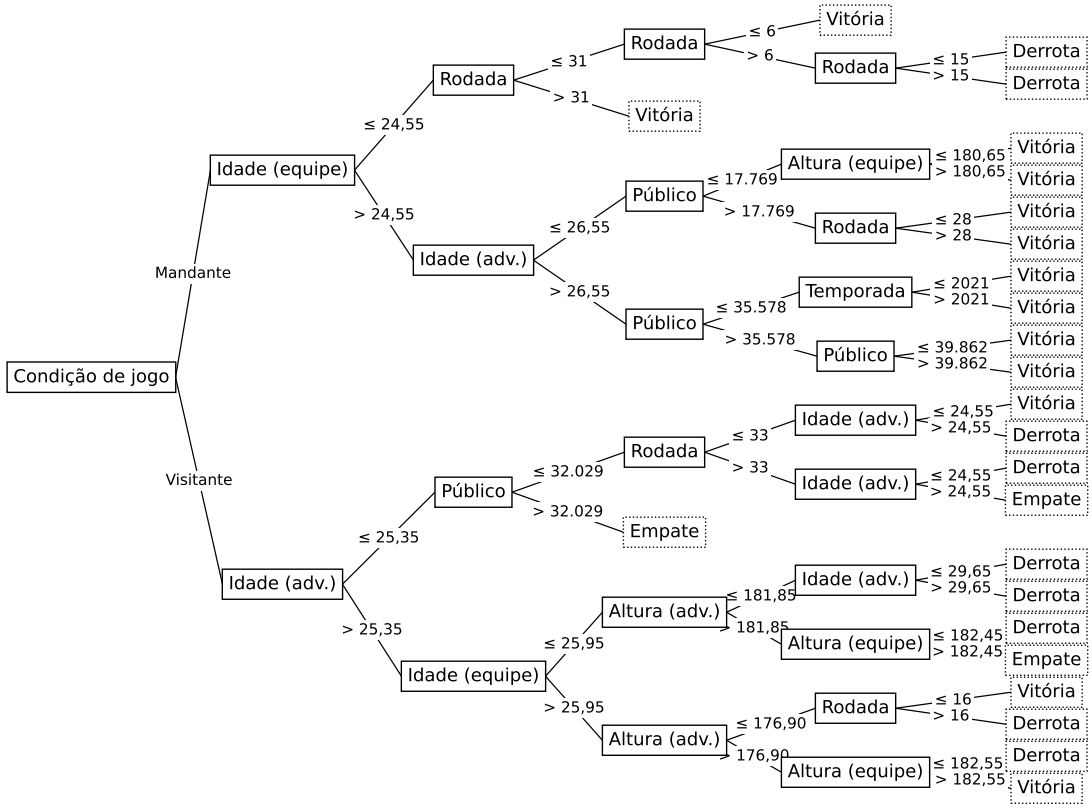


Figura 5. Árvore de decisão do Clube dos 13 contra os demais adversários (sem os clubes do Z4). As caixas com borda contínua indicam a variável testada, e as caixas pontilhadas, a classe prevista. (adv. = adversário)

tamanhos muito diferentes (984 e 3.781 registros), e essa diferença também pode alterar a distribuição da importância.

Na estrutura da árvore, após o mando, o clube que joga em casa é dividido pela idade média dos titulares da equipe (24,55 anos), e o que joga fora de casa, pela idade média dos titulares do adversário (25,35 anos). Das 25 folhas, 12 correspondem a jogos em casa (10 indicam Vitória e 2, Derrota) e 13 a jogos fora de casa (7 indicam Derrota, 3 Vitória e 3 Empate). Em casa, quando a idade média dos titulares da equipe passa de 24,55 anos, todas as oito folhas do ramo indicam Vitória, independentemente das demais variáveis, o que significa que as divisões seguintes reduziram a mistura entre as classes sem alterar a previsão final. As duas folhas de Derrota em casa aparecem no ramo de equipes com idade média de até 24,55 anos, em rodadas entre a 7ª e a 31ª, mas esse ramo provavelmente envolve poucas partidas, e qualquer interpretação é apenas uma hipótese. O público, a rodada e as idades aparecem em várias divisões, e os limiares do público (de cerca de 18 mil a 40 mil pessoas) não foram investigados. Como em outros recortes, a idade e a altura médias dos titulares variam pouco entre partidas de uma mesma temporada e podem estar refletindo características de cada clube, e não um efeito direto sobre o resultado.

Em resumo, a comparação entre os dois recortes mostra dois contrastes. No resul-

tado, os clubes do *C13* venceram 55,7% dos jogos contra o Z4 e 38,1% contra os demais adversários (Tabela 4). Na árvore, o mando concentra a maior parte da importância contra os demais adversários e uma parcela bem menor contra o Z4, onde as características físicas dos elencos ganham peso. Ambos os contrastes são associações observadas nos dados, e não explicações causais. Cabe lembrar que as taxas acima consideram todos os jogos, enquanto as árvores usam os registros após a limpeza (984 contra o Z4 e 3.781 contra os demais adversários), o que explica pequenas diferenças, como 55,7% e 55,9% de vitórias contra o Z4.

4.5. Árvore de decisão do Atlético Mineiro

Como estudo de caso, foi construída uma árvore a partir das partidas do Atlético Mineiro, totalizando 414 registros e 14 atributos após a limpeza. A configuração selecionada foi *max_depth*=5, *min_samples_leaf*=5 e *min_samples_split*=2, com critério *entropy* e validação cruzada estratificada com 5 *folds*. As classes apresentam distribuição de 184 vitórias (44,4%), 123 derrotas (29,7%) e 107 empates (25,8%), sendo o *baseline*, portanto, de 44,4%. Por se tratar de um único clube, este recorte tem caráter exploratório.

O Atlético Mineiro foi selecionado como estudo de caso por sua representatividade histórica, sendo o primeiro campeão brasileiro em 1971, e por razões metodológicas específicas. Em primeiro lugar, o clube ocupa uma posição intermediária entre os times do *C13* nos jogos contra o Z4: seu aproveitamento (65,53%) é o quinto maior do grupo e está a menos de um ponto percentual do aproveitamento do conjunto (64,63%), o que permite verificar se os padrões gerais se mantêm em uma equipe sem desempenho extremamente discrepante. Além disso, o clube disputou todas as onze temporadas da Série A no período, garantindo uma série contínua de dados. Por fim, o conhecimento prévio sobre o contexto do clube auxilia na interpretação dos resultados observados nas árvores.

A árvore, representada na Figura 6 obteve *accuracy* de 42,51%, *balanced accuracy* de 38,08% e *F1-macro* de 37,54%. A *accuracy* ficou, assim, ligeiramente abaixo do *baseline* (44,4%), o que indica que, neste recorte, os atributos utilizados não foram suficientes para superar a previsão da classe mais frequente. O desvio-padrão da *accuracy* entre os *folds* foi de 0,075, com valores variando de 30,1% a 50,6%, o que evidencia a instabilidade típica de amostras pequenas: cada *fold* de teste contém cerca de 83 partidas, de modo que poucos acertos ou erros alteram sensivelmente a métrica. Por classe, o *recall* foi de 63,6% para Vitória, 30,1% para Derrota e 20,6% para Empate, com precisões de 49,6%, 35,6% e 29,7%, respectivamente. Assim como na árvore geral, a classe Empate foi a de menor capacidade de identificação.

Quanto à importância das variáveis, o público (0,1871) e a temporada (0,1856) ocuparam as primeiras posições, seguidos pela condição de mando (0,1465) e pela altura média dos titulares do adversário (0,1357). Diferentemente da árvore geral, na qual o mando de campo concentrou 0,5748 da importância, aqui nenhuma variável ultrapassou 0,19, o que indica uma distribuição mais equilibrada entre os fatores. Essa comparação é possível porque ambas as árvores possuem a mesma profundidade, mas a diferença no tamanho das amostras deve ser considerada.

Na estrutura da árvore, a primeira divisão ocorre pela condição de mando. Quando o Atlético joga em casa contra adversários com altura média dos titulares inferior ou igual a 181,85 cm, todas as folhas do ramo resultam em Vitória, independentemente das

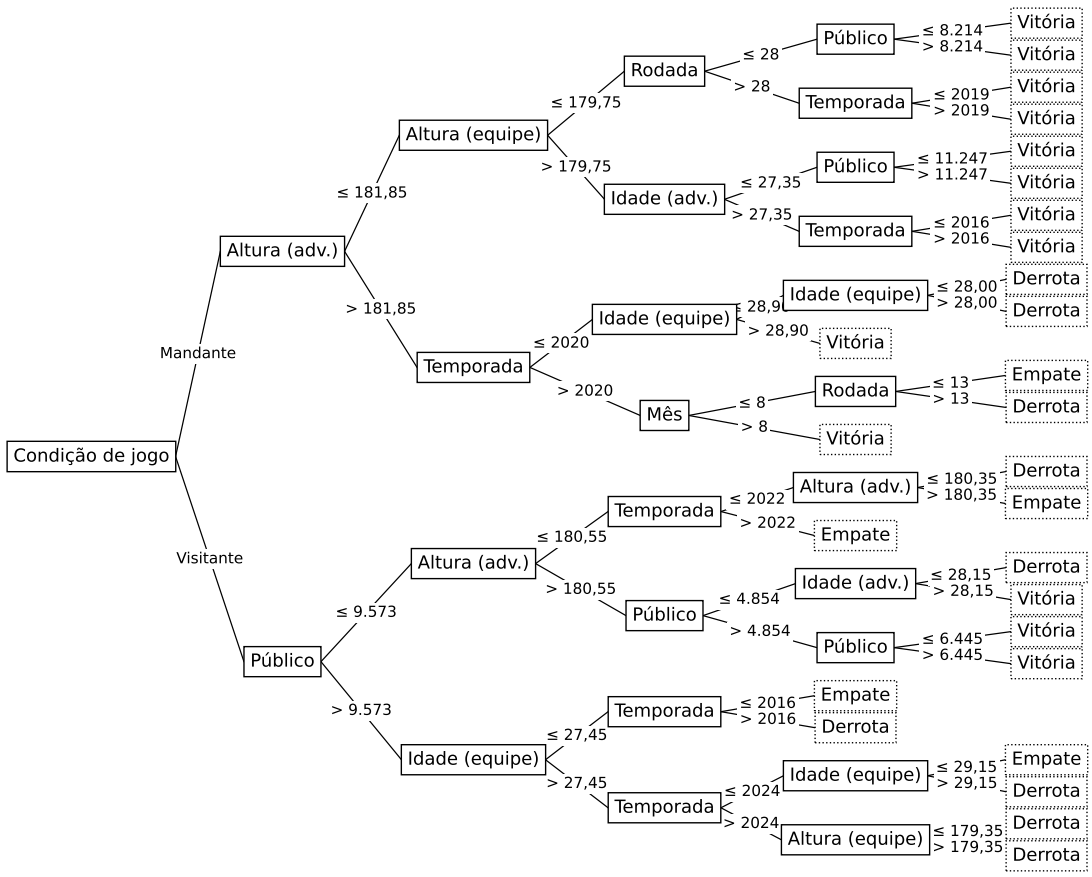


Figura 6. Árvore de decisão do Atlético Mineiro. As caixas com borda contínua indicam a variável testada, e as caixas pontilhadas, a classe prevista. (adv. = adversário)

demais variáveis. Para adversários mais altos, a árvore passa a distinguir os resultados pela temporada, pela idade média dos titulares da equipe e, nas temporadas mais recentes, pelo mês e pela rodada. No ramo em que o time joga fora de casa, predominam previsões de Empate e Derrota, com participação do público e da idade média dos titulares.

Dois aspectos merecem destaque na interpretação. O primeiro é a presença da variável *temporada* entre as mais importantes. Em um recorte restrito a um único clube, atributos como idade e altura médias dos titulares da equipe variam principalmente entre temporadas (pela renovação do elenco) e pouco entre partidas de uma mesma temporada, de modo que esses atributos e a própria temporada podem funcionar como indicadores do período do clube, e não como fatores independentes. O segundo é que, pelo mesmo motivo, divisões em torno de determinados anos (por exemplo, 2020 e 2024) devem ser vistas como possível reflexo de mudanças de elenco, comissão técnica ou contexto do clube, o que não pode ser confirmado com os dados disponíveis. Essas observações caracterizam peculiaridades do clube analisado, mas, dada a amostra reduzida e a instabilidade entre os *folds*, não devem ser generalizadas para outros times.

Os resultados do Atlético Mineiro também podem ser relacionados à análise anterior sobre os jogos contra o Z4. Conforme a Tabela 4, o clube venceu 56,8% dos jogos

contra o Z4 e 41,0% contra os demais adversários, uma diferença de 15,8 pontos percentuais, próxima à do conjunto dos clubes (17,6). Ou seja, o padrão de vencer mais contra os rebaixados se repete no estudo de caso. Já a árvore foi construída com todos os jogos do clube (414 registros) e, por isso, não isola os jogos contra o Z4. Nela, o mando aparece entre as variáveis mais importantes (0,1465), como no conjunto, mas com peso bem menor do que na árvore geral (0,5748), enquanto o público e a temporada aparecem à frente, o que sugere que, para o Atlético, o período e o público ajudam a descrever os resultados mais do que no conjunto dos clubes. Essa leitura deve ser entendida como uma associação observada em uma amostra pequena, e não como uma explicação dos resultados do clube contra os rebaixados.

4.6. Importância das variáveis ao longo das temporadas

Para analisar como a importância das variáveis se comporta ao longo do tempo, foi construída uma árvore de decisão para cada temporada entre 2015 e 2025, todas com profundidade máxima igual a 5 e validação cruzada com 5 *folds*. A profundidade foi fixada porque a importância depende do número de divisões da árvore, como explicado na Metodologia. Os resultados são apresentados por meio de três visões complementares: a presença de cada variável entre as cinco mais importantes de cada ano, a frequência dessa presença ao longo da série e a distribuição da importância por grupo de variáveis. Em todas elas, as explicações apresentadas devem ser entendidas como hipóteses, exceto quando indicado que foram verificadas nos dados.

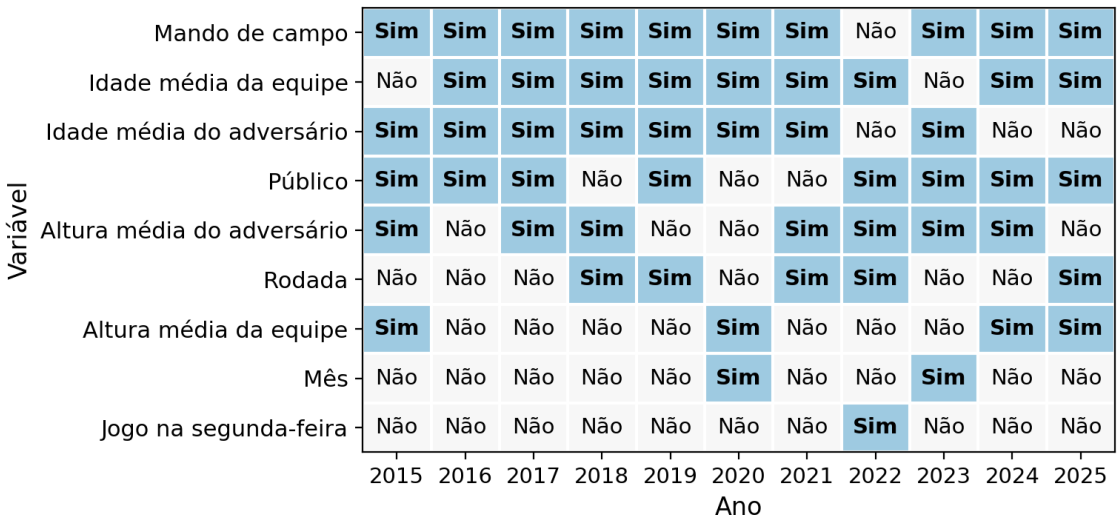


Figura 7. Presença de cada variável entre as cinco mais importantes em cada temporada (2015 a 2025).

A Figura 7 indica, para cada temporada, quais variáveis ocuparam as cinco primeiras posições de importância. A condição de mando (*condicao_Visitante*) esteve presente em todos os anos, exceto em 2022. As idades médias dos titulares da equipe e do adversário também aparecem na maior parte da série: a da equipe está ausente apenas em 2015 e 2023, e a do adversário, em 2022, 2024 e 2025. O público e a altura média dos titulares do adversário alternam presença e ausência, enquanto a rodada, a altura média dos titulares da equipe, o mês e o dia da semana aparecem de forma esporádica. A matriz

informa apenas se a variável esteve entre as cinco primeiras, e não a magnitude de sua importância, que é tratada adiante.

Podemos observar que em 2020, em que o público foi constante, o top 5 incluiu a altura média dos titulares da equipe e o mês, variáveis pouco frequentes nos demais anos. Em 2024 e 2025, quatro das cinco variáveis são as mesmas (condição de mando, idade e altura médias dos titulares da equipe e público), o que sugere certa estabilidade nas temporadas mais recentes, embora a série seja curta para qualquer conclusão nesse sentido.

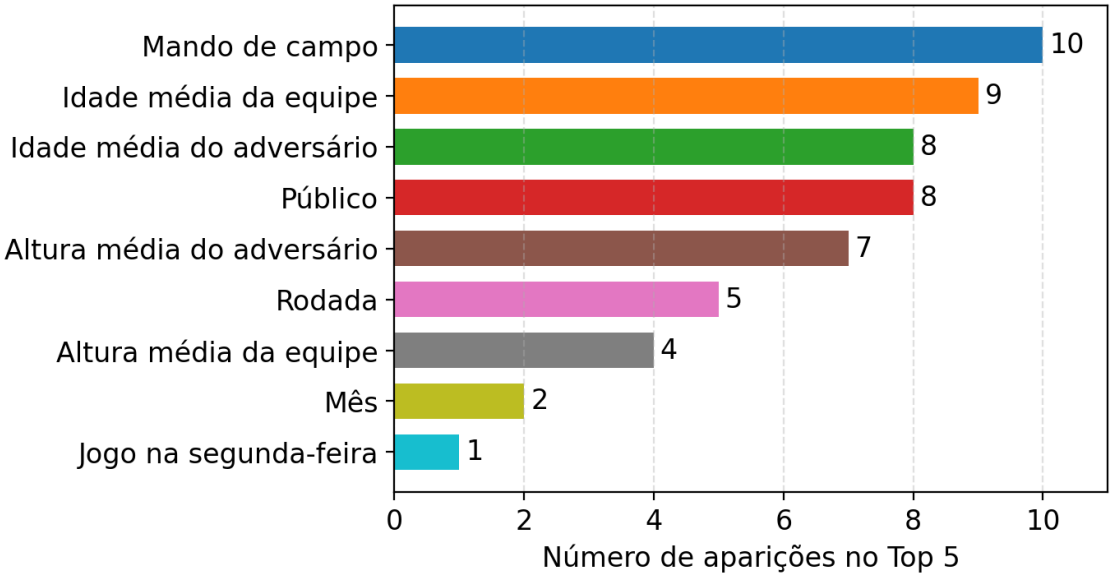


Figura 8. Número de temporadas em que cada variável esteve entre as cinco mais importantes.

A Figura 8 resume a matriz em número de aparições. A condição de mando foi a mais frequente (10 das 11 temporadas), seguida pela idade média dos titulares da equipe (9), pela idade média dos titulares do adversário (8), pelo público (8) e pela altura média dos titulares do adversário (7). Mais abaixo aparecem a rodada (5), a altura média dos titulares da equipe (4), o mês (2) e o dia da semana, representado pela variável *dia_semana_Segunda* (1). Assim, o mando de campo, a idade dos elencos e o público formam o conjunto mais recorrente, ao passo que variáveis de calendário e a altura da própria equipe têm presença mais ocasional. Cabe observar que a frequência no top 5 não distingue uma variável que ocupa a primeira posição de outra que apenas alcança a quinta.

A Figura 9 mostra, por grupo de variáveis, como a importância somada se distribuiu entre as temporadas, por meio de *boxplots*[13], com um ponto por ano. A condição de mando apresentou a maior mediana (cerca de 0,21) e o primeiro quartil (cerca de 0,17) acima das medianas de todos os demais grupos, o que a torna a variável mais consistentemente relevante da série. Sua dispersão, entretanto, é ampla, de aproximadamente 0,10 (valor de 2022) a 0,37, o que mostra que a importância do mando varia bastante de um

[13]Gráfico que resume a distribuição de um conjunto de valores por meio da mediana, dos quartis e dos valores extremos.

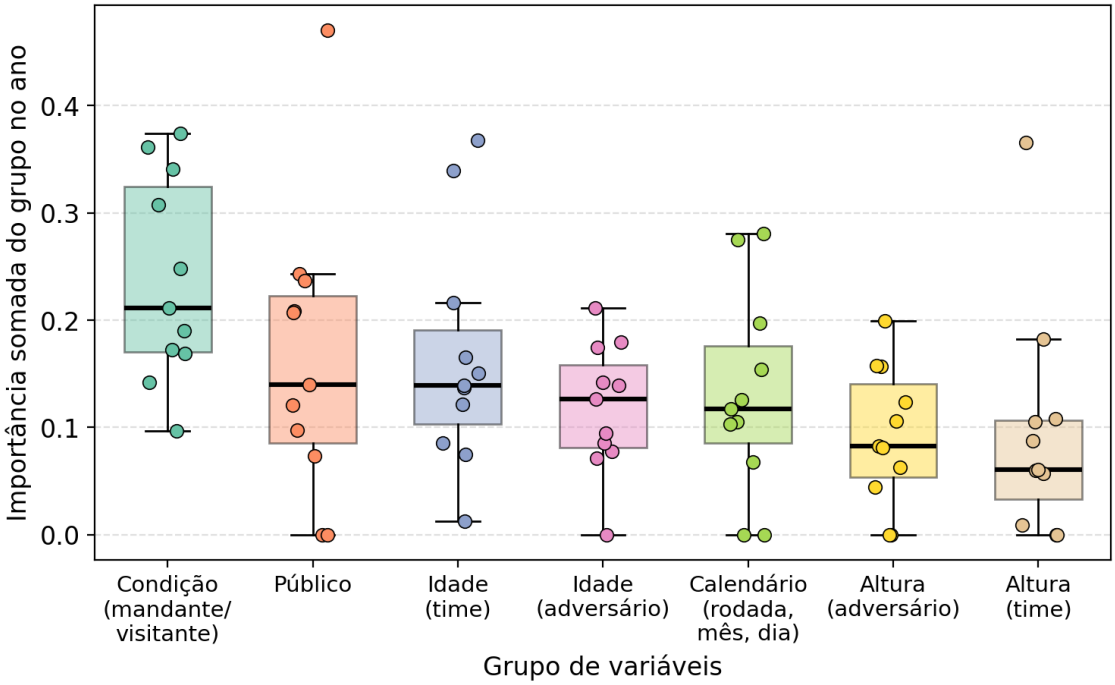


Figura 9. Distribuição da importância somada de cada grupo de variáveis ao longo das temporadas de 2015 a 2025. Cada ponto representa uma temporada.

ano para outro. O público teve mediana em torno de 0,14, com dois anos de importância igual a zero (compatíveis com 2020 e 2021, explicados adiante) e um valor atípico próximo de 0,47 que ocorreu em 2016. As idades médias dos titulares da equipe e do adversário tiveram medianas próximas (cerca de 0,14 e 0,13), sendo a da equipe marcada por dois valores atípicos (cerca de 0,34, em 2018, e 0,37). O calendário (rodada, mês e dia da semana) e a altura do adversário apresentaram medianas de cerca de 0,12 e 0,08, e a altura da equipe teve a menor mediana (cerca de 0,06), com um valor atípico de 0,3653, referente a 2015.

Esses resultados devem ser lidos com cautela. Como há apenas 11 temporadas por grupo, grupos com valores próximos (como público e idades) não podem ser considerados diferentes entre si. Além disso, o grupo do calendário reúne várias variáveis (rodada, mês e dias da semana), o que favorece a sua importância somada, ao passo que o mando é representado por uma única variável, o que torna seu resultado mais notável. Os valores atípicos de idade da equipe (2018) e de altura da equipe (2015) são anos em que um único atributo concentrou boa parte da importância e são discutidos a seguir.

A seguir, são discutidos alguns casos que chamaram atenção nas figuras.

4.6.1. Condição de mando de campo em 2022

A ausência de *condicao_Visitante* do top 5 em 2022 foi o resultado mais inesperado, uma vez que o efeito do mando de campo é amplamente documentado [Carlet 2015, Nascimento and Silva 2020]. A verificação nos dados mostrou que, nessa temporada, a

vantagem de mandar o jogo foi a menor de toda a série: no recorte analisado, o mandante venceu 53,2% das partidas e o visitante, 37,4%, uma diferença de 15,8 pontos percentuais (p.p.), contra uma média de aproximadamente 25,9 pontos nas demais temporadas. Ainda assim, o mandante venceu mais do que o visitante em todas as onze temporadas, com diferenças entre 15,8 e 37,0 pontos percentuais, o que está em linha com esses estudos, que também encontraram mais vitórias dos mandantes no Campeonato Brasileiro. A Tabela 6 relaciona essa diferença à importância da variável em todas as temporadas, ordenadas da menor para a maior diferença.

Tabela 6. Diferença entre a taxa de vitórias do mandante e do visitante e importância de *condicao_Visitante*, por temporada.

Temporada	Diferença (p.p.)	Importância
2022	15,8	0,0968
2017	19,7	0,1418
2020	20,2	0,1902
2024	22,4	0,1687
2019	22,7	0,2482
2023	22,7	0,2110
2021	25,8	0,1725
2016	26,4	0,3075
2025	29,6	0,3743
2015	32,1	0,3408
2018	37,0	0,3610

Nas onze temporadas, a importância da variável tende a acompanhar a magnitude da vantagem de mando. Nos anos de menor diferença (2022, 2017 e 2020), a importância é baixa, e nos anos de maior diferença (2016, 2025, 2015 e 2018) ela passa de 0,30. Cabe ressaltar que esses valores foram calculados apenas com as partidas do recorte do Clube dos 13, que em 2022 contou com 9 clubes, o menor número entre as temporadas analisadas, e que, portanto, não representam necessariamente o Campeonato Brasileiro como um todo. Como hipótese complementar, a redução da vantagem de mando em 2022 pode estar relacionada ao calendário atípico daquela temporada, associado à Copa do Mundo. Na mesma temporada, a variável *dia_semana_Segunda* apareceu no top 5 (0,1115), o que pode refletir a concentração de jogos nesse dia, mas essa relação não foi testada.

Cabe ressaltar que esses valores foram calculados apenas com as partidas do recorte do Clube dos 13, que em 2022 contou com 9 clubes, o menor número entre as temporadas analisadas, e que, portanto, não representam necessariamente o Campeonato Brasileiro como um todo.

Outra hipótese seria a volta gradual do público aos estádios após a pandemia. Estudos sobre a Série A, porém, não encontraram efeito significativo da presença da torcida no desempenho dos mandantes ao comparar temporadas com e sem público [dos Santos et al. 2023], e indicam que a vantagem de mando já vinha diminuindo antes de 2020, em um período que coincide com a introdução do árbitro de vídeo [Ribeiro et al. 2022]. Assim, a redução observada em 2022 não pode ser atribuída à torcida a partir dos dados deste trabalho.

4.6.2. Público em 2018, 2020 e 2021

O público não esteve entre as cinco variáveis mais importantes em 2018. Nos dados do recorte, a média de público foi de 22.324 pessoas, abaixo de outras temporadas, como 2023 (32.111), e variou pouco conforme o resultado (22.583 em derrotas, 21.727 em empates e 22.570 em vitórias). Essa semelhança, porém, não explica sozinha a ausência da variável, pois em 2015 e 2022 as médias por resultado também foram próximas e o público entrou no top 5 (em 2022, na primeira posição). Uma possibilidade é que, em 2018, a importância tenha se concentrado em duas variáveis, a condição de mando (0,3610) e a idade média dos titulares da equipe (0,3396), que somam cerca de 0,70, em um ano que teve a maior vantagem de mando da série (37,0 pontos percentuais). Assim, a ausência do público em 2018 permanece parcialmente sem explicação conclusiva.

Por outro lado, em 2020 e 2021 a ausência do público tem explicação direta nos dados e está associada à pandemia de COVID-19, que levou à realização de partidas sem torcida. Em 2020, todas as partidas tiveram público igual a zero, de modo que a variável é constante e não pode ser utilizada em divisões. Em 2021, mais da metade das partidas (mediana igual a zero) foi realizada sem torcida, com retorno parcial do público ao longo da temporada.

5. Conclusões e trabalhos futuros

Este trabalho investigou, com base em dados, o desempenho dos clubes do Clube dos 13 contra os times da zona de rebaixamento (Z4) na Série A entre 2015 e 2025. Foram coletadas 4.898 registros de partidas (3.498 partidas únicas) e construídas árvores de decisão para o conjunto dos clubes, para os jogos contra o Z4, para os jogos contra os demais adversários, para o Atlético Mineiro e para cada temporada, com o objetivo de identificar fatores associados ao resultado.

Quanto à pergunta central do trabalho, os resultados não sustentam a ideia de que os grandes clubes têm uma dificuldade específica contra os times do Z4. Os tropeços existem: nos jogos contra o Z4, os clubes do *C13* venceram 55,7% das partidas, empataram 26,8% e perderam 17,5%, ou seja, deixaram de vencer em cerca de 44% dos jogos. No entanto, a taxa de vitórias contra o Z4 foi bem maior que a obtida contra os demais adversários (38,1%), uma diferença de cerca de 18 pontos percentuais que aparece nos treze clubes. Assim, os dados indicam que esses clubes se saem melhor contra os rebaixados do que contra os demais adversários, e que os pontos perdidos contra o Z4 não caracterizam, por si só, uma dificuldade particular desse grupo de adversários. O desempenho varia bastante entre os clubes: Palmeiras (76,89%) e Flamengo (74,62%) tiveram os maiores aproveitamentos, e Vasco da Gama (54,44%), Cruzeiro (58,60%) e Santos (59,40%), os menores. O Atlético Mineiro, estudo de caso do trabalho, ficou na quinta posição, com aproveitamento de 65,53% e média de 1,03 ponto perdido por jogo, atrás de Palmeiras, Flamengo, Grêmio e Corinthians, e venceu 56,8% dos jogos contra o Z4 e 41,0% contra os demais adversários, padrão semelhante ao do conjunto dos clubes.

Nas árvores de decisão, a condição de mando foi o fator mais associado ao resultado no conjunto dos clubes, com a primeira divisão da árvore e importância de 0,5748. Contra o Z4, o mando continuou sendo a primeira divisão da árvore, mas com uma parcela bem menor (0,1769), praticamente igual à da altura média dos titulares da equipe

(0,1771), e a importância ficou mais distribuída entre a idade média dos titulares do adversário (0,1348), a altura média dos titulares do adversário (0,1044) e a idade média dos titulares da equipe (0,1014). Uma possível leitura é que, contra equipes rebaixadas, o mando de campo perde parte de sua capacidade de distinguir os resultados: contra os demais adversários, a condição de mando concentrou 0,6104 da importância. Essa, porém, é uma hipótese que não foi testada diretamente, já que os recortes têm tamanhos diferentes. Na análise por temporada, a condição de mando esteve entre as cinco variáveis mais importantes em 10 das 11 temporadas, e sua importância acompanhou a diferença entre as taxas de vitória do mandante e do visitante, sendo 2022 a temporada de menor diferença e a única em que a variável ficou fora do top 5. As idades médias dos titulares e o público também apareceram com frequência, e a ausência do público em 2020 e 2021 está ligada à pandemia de *COVID-19*.

O desempenho dos modelos foi modesto. A árvore geral teve *accuracy* de 48,65%, acima do *baseline* (41,7%), mas identificou poucos empates (*recall* de 3,0%). Contra o Z4 e no recorte do Atlético Mineiro, a *accuracy* ficou abaixo do *baseline*. Isso indica que as variáveis disponíveis ajudam a descrever associações com o resultado, mas não bastam para prever cada partida, o que é compatível com a imprevisibilidade do futebol. Como o objetivo do trabalho foi compreender os fatores associados ao resultado, e não maximizar a previsão, as árvores cumprem esse papel, desde que seus resultados sejam interpretados com as limitações a seguir.

Algumas limitações devem ser consideradas. Os recortes contra o Z4 (984 registros) e do Atlético Mineiro (414 registros) são pequenos, o que torna as métricas instáveis entre as partes da validação cruzada, e por isso os resultados do Atlético, em particular, não devem ser generalizados para outros clubes. Além disso, o Z4 é definido pela classificação final de cada temporada, e não pela posição do adversário no momento do jogo. Por fim, nas temporadas de 2020 e 2021, as partidas sem torcida em razão da pandemia foram mantidas com público igual a zero, de modo que, nesses anos, a variável público reflete as restrições sanitárias e não o interesse pelas partidas.

Os resultados também abrem caminho para novas investigações. Uma possibilidade é enriquecer a base com outras informações do contexto das partidas, como variáveis climáticas (a ocorrência de chuva no local e no horário do jogo), a posição do adversário na tabela no momento da partida e o desempenho recente do clube. Outra é ampliar a comparação: observar o desempenho contra outros grupos de adversários, como os times do meio da tabela, permitiria verificar se o padrão encontrado é específico dos rebaixados, e repetir a análise de forma individual para outros clubes serviria de contraste ao estudo de caso do Atlético Mineiro. Por fim, o uso de outros algoritmos de classificação, como florestas aleatórias, permitiria comparar seus resultados com os das árvores de decisão.

Referências

Carlet, R. (2015). Fator local e sua influência no futebol: análise quantitativa do campeonato brasileiro série a. *Revista Brasileira de Futsal e Futebol*, 7(26):399–407.

Cayo, I. (2013). Geografizando o futebol: do global ao local. `https://www2.ifrn.edu.br/ojs/index.php/HOLOS/article/download/1333/685`. Acesso em: 21 set. 2026.

de Carvalho, F. C. N. (2022). Comparação do desempenho técnico entre locais de jogo e formatos de competição em um time de elite do futebol brasileiro. Trabalho de Conclusão de Curso (Graduação).

dos Santos, A. A., Silva, P. C. R., Pereira, A. S., Silva, A. d. S., Silva, A. d. A., and Santos, D. R. S. (2023). Torcida ganha jogo? possíveis efeitos da covid-19 na vantagem em casa nas séries a e b do campeonato brasileiro de futebol. *Conexões*, 21:e023008.

Nascimento, M. S. L. d. and Silva, D. C. d. (2020). Análise da vantagem de jogar em casa em diferentes ligas do futebol mundial. *Revista Brasileira de Futsal e Futebol*, 12(49):371–375.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning*, 1(1):81–106.

Ribeiro, L. d. C., Fonseca, F. d. S., Costa, G. D. C. T., Castro, H. d. O., Santos, J. P. V. d. S., and Figueiredo, L. S. (2022). Did the absence of crowd support during the covid-19 pandemic affect the home advantage in brazilian elite soccer? *Journal of Human Kinetics*, 81:251–258.

Rosa, P. H. C. (2022). Mineração de dados aplicada a previsão de resultados de jogos de futebol. Trabalho de Conclusão de Curso (Graduação).

Souza, A. M. (2024). Predição de resultados de jogos do campeonato brasileiro de futebol feminino. Trabalho de Conclusão de Curso (Graduação).

Triches, V. (2020). O futebol como elemento de identificação social e patrimônio cultural do brasil: dos primórdios a contemporaneidade do esporte bretão. `https://periodicos.ufpe.br/revistas/esportecoletivo/article/download/249795/37845`. Acesso em: 21 set. 2026.